

EMSI Casablanca

École Marocaine des Sciences de l'Ingénieur



Filière : Informatique

Projet de Fin de Module

Module : Deep Learning

Conception, Implémentation, Comparaison et Analyse Critique
de Modèles de Deep Learning pour Données Tabulaires,
Images et Séquences

Réalisé par : **Lasri Mohamed Amine**

Groupe : 1

Encadrante : Mme. HIDILA Zineb

Année universitaire : 2025–2026

Table des matières

1	Introduction générale	3
1.1	Contexte et problématique	3
1.2	Objectifs du projet	3
1.3	Organisation du rapport	4
2	Partie I — MLP et Ingénierie PyTorch	5
2.1	Cadre théorique	5
2.1.1	Le Perceptron Multicouche (MLP)	5
2.1.2	Concepts fondamentaux PyTorch	5
2.1.3	Stratégies d’initialisation	7
2.2	Dataset et préparation des données	8
2.2.1	Choix du dataset : Breast Cancer Wisconsin	8
2.2.2	Pipeline de prétraitement	8
2.3	Implémentation des modèles	9
2.3.1	Version nn.Sequential	9
2.3.2	Version classe personnalisée	10
2.3.3	Boucle d’entraînement	10
2.4	Résultats expérimentaux	11
2.4.1	Comparaison des initialisations	11
2.4.2	Métriques finales sur le test set	11
2.4.3	Visualisation de la convergence	12
2.5	Question de synthèse — Partie I	12
3	Partie II — CNN et Vision par Ordinateur	14
3.1	Cadre théorique	14
3.1.1	Limites du MLP pour les images	14
3.1.2	Corrélation croisée 2D	14
3.1.3	Pooling	15
3.1.4	Implémentations manuelles	15
3.2	Dataset et préparation	16
3.2.1	Choix : CIFAR-10	16
3.3	Architecture CNN (inspirée de LeNet)	16

3.4	Étude expérimentale	17
3.4.1	Influence des hyperparamètres architecturaux	18
3.4.2	Courbes d'apprentissage	18
3.5	Question de synthèse — Partie II	18
4	Partie III — RNN, LSTM, GRU et Seq2Seq	20
4.1	Cadre théorique	20
4.1.1	Modèles de langage	20
4.1.2	RNN simple et ses limites	20
4.1.3	LSTM	21
4.1.4	GRU	21
4.2	Dataset et préparation	21
4.2.1	Choix : corpus fra-eng (Tatoeba)	21
4.3	Implémentation des modèles	22
4.3.1	RNN, LSTM et GRU	22
4.3.2	Architecture Seq2Seq	23
4.3.3	Décodage : glouton et beam search	25
4.4	Résultats expérimentaux	25
4.4.1	Comparaison RNN / LSTM / GRU	26
4.4.2	Effet du gradient clipping	26
4.5	Question de synthèse — Partie III	26
5	Discussion Transversale Finale	28
5.1	Unité du paradigme : gradient et rétropropagation	28
5.2	Tableau comparatif des architectures	29
5.3	Adéquation données–modèle : la clé du succès	29
5.4	Perspectives : au-delà des architectures classiques	30
6	Conclusion	31
	Bibliographie	32
A	Hyperparamètres complets	33
B	Checklist de reproductibilité	34
B.1	Annexe C - Requirements.txt	34

Chapitre 1

Introduction générale

Le **deep learning** constitue aujourd’hui l’un des paradigmes les plus puissants de l’intelligence artificielle. En s’appuyant sur des architectures de réseaux de neurones profonds, il permet d’extraire automatiquement des représentations hiérarchiques à partir de données brutes, éliminant ainsi la nécessité d’une ingénierie manuelle de caractéristiques (*feature engineering*).

1.1 Contexte et problématique

L’un des défis fondamentaux du deep learning consiste à *adapter l’architecture au type de données*. En effet, la géométrie inhérente aux données — structure tabulaire, grille spatiale pour les images, ou dépendances temporelles pour les séquences — impose des choix architecturaux distincts. Ce projet explore cette question centrale à travers trois grandes familles de modèles :

1. **Partie I — MLP** : classification supervisée sur données tabulaires.
2. **Partie II — CNN** : classification d’images et analyse convolutionnelle.
3. **Partie III — RNN/LSTM/GRU/Seq2Seq** : modélisation de séquences textuelles.

1.2 Objectifs du projet

- Maîtriser l’implémentation sous PyTorch des architectures fondamentales.
- Conduire des expériences comparatives rigoureuses et reproductibles.
- Analyser critiqueusement les résultats en reliant théorie et pratique.
- Répondre à la problématique transversale : *comment le deep learning adapte-t-il ses architectures à la structure des données ?*

1.3 Organisation du rapport

Ce rapport est structuré en fins chapitres : trois parties techniques (MLP, CNN, RNN/Seq2Seq), une discussion transversale finale, et une conclusion générale. Chaque partie technique suit le même canevas : cadre théorique, implémentation PyTorch, étude expérimentale, analyse critique et question de synthèse.

Chapitre 2

Partie I — MLP et Ingénierie PyTorch

2.1 Cadre théorique

2.1.1 Le Perceptron Multicouche (MLP)

Définition 2.1 (Perceptron Multicouche). *Un MLP est un réseau de neurones entièrement connecté composé d'une couche d'entrée, de L couches cachées et d'une couche de sortie. La transformation effectuée par la l -ième couche s'écrit :*

$$\mathbf{h}^{(l)} = f\left(\mathbf{W}^{(l)}\mathbf{h}^{(l-1)} + \mathbf{b}^{(l)}\right) \quad (2.1)$$

où $\mathbf{W}^{(l)} \in \mathbb{R}^{d_l \times d_{l-1}}$ est la matrice de poids, $\mathbf{b}^{(l)} \in \mathbb{R}^{d_l}$ le vecteur de biais, et f une fonction d'activation non linéaire.

2.1.2 Concepts fondamentaux PyTorch

`nn.Module`

La classe `nn.Module` est la brique de base de tout modèle PyTorch. Elle gère automatiquement les paramètres, leur déplacement sur GPU, et leur sérialisation.

Structure d'un nn.Module

```

1 import torch
2 import torch.nn as nn
3
4 class MLP(nn.Module):
5     def __init__(self, input_dim, hidden_dims,
6                   output_dim, dropout=0.3):
7         super(MLP, self).__init__()
8         layers = []
9         prev_dim = input_dim
10        for h in hidden_dims:
11            layers += [
12                nn.Linear(prev_dim, h),
13                nn.BatchNorm1d(h),
14                nn.ReLU(),
15                nn.Dropout(dropout)
16            ]
17            prev_dim = h
18        layers.append(nn.Linear(prev_dim, output_dim))
19        self.network = nn.Sequential(*layers)
20
21    def forward(self, x):
22        return self.network(x)

```

Propagation avant et rétropropagation

La **propagation avant** calcule la perte $\mathcal{L}$ à partir des entrées. La **rétropropagation** applique la règle de la chaîne pour calculer les gradients :

$$\frac{\partial \mathcal{L}}{\partial \mathbf{W}^{(l)}} = \frac{\partial \mathcal{L}}{\partial \mathbf{h}^{(l)}} \cdot \frac{\partial \mathbf{h}^{(l)}}{\partial \mathbf{W}^{(l)}} = \boldsymbol{\delta}^{(l)} \cdot (\mathbf{h}^{(l-1)})^\top \quad (2.2)$$

où $\boldsymbol{\delta}^{(l)}$ est le signal d'erreur rétropropagé.

state_dict et paramètres

```

1 # Inspection des parametres
2 for name, param in model.named_parameters():
3     print(f"{name}: shape={param.shape}, "
4           f"requires_grad={param.requires_grad}")
5
6 # Sauvegarde du meilleur modele

```

```

7 torch.save(model.state_dict(), "best_model.pth")
8
9 # Rechargement
10 model_loaded = MLP(input_dim, hidden_dims, output_dim)
11 model_loaded.load_state_dict(torch.load("best_model.pth"))
12 model_loaded.eval()

```

Listing 2.1 – Inspection des paramètres et sauvegarde du modèle

Gestion CPU/GPU

```

1 device = torch.device("cuda" if torch.cuda.is_available()
   else "cpu")
2 model = model.to(device)
3
4 % Les donnees doivent etre sur le meme device
5 X_batch = X_batch.to(device)
6 y_batch = y_batch.to(device)

```

Listing 2.2 – Transfert modèle et données sur GPU

2.1.3 Stratégies d'initialisation

L'initialisation des poids influence fortement la convergence. Trois stratégies ont été comparées :

Initialisations testées

$$\text{Gaussienne : } W \sim \mathcal{N}(0, 0.01^2) \quad (2.3)$$

$$\text{Constante : } W = 0 \quad (\text{brise la symétrie si } \neq 0) \quad (2.4)$$

$$\text{Xavier : } W \sim \mathcal{U}\left(-\sqrt{\frac{6}{n_{\text{in}}+n_{\text{out}}}}, \sqrt{\frac{6}{n_{\text{in}}+n_{\text{out}}}}\right) \quad (2.5)$$

Xavier est recommandée car elle préserve la variance des activations à travers les couches [1].

```

1 def init_weights(m, strategy="xavier"):
2     if isinstance(m, nn.Linear):
3         if strategy == "gaussian":
4             nn.init.normal_(m.weight, mean=0, std=0.01)
5         elif strategy == "constant":
6             nn.init.constant_(m.weight, 0.01)

```

```
7         elif strategy == "xavier":  
8             nn.init.xavier_uniform_(m.weight)  
9             nn.init.zeros_(m.bias)  
10  
11 model.apply(lambda m: init_weights(m, strategy="xavier"))
```

Listing 2.3 – Implémentation des initialisations

2.2 Dataset et préparation des données

2.2.1 Choix du dataset : Breast Cancer Wisconsin

Le dataset *Breast Cancer Wisconsin* (UCI) est retenu pour cette partie. Il contient **569 échantillons** décrits par **30 features** numériques (moyennes, erreurs-types et pires valeurs de 10 mesures cellulaires), avec une variable cible binaire (malin / bénin).

Statistiques du dataset

- Échantillons : 569 (212 malins, 357 bénins)
- Features : 30 (toutes numériques, aucune valeur manquante)
- Déséquilibre : 37 % / 63 % $\Rightarrow$ modéré, gérable par pondération de la perte

2.2.2 Pipeline de prétraitement

```
1 from sklearn.datasets import load_breast_cancer  
2 from sklearn.model_selection import train_test_split  
3 from sklearn.preprocessing import StandardScaler  
4 import torch  
5 from torch.utils.data import DataLoader, TensorDataset  
6  
7 # Chargement  
8 data = load_breast_cancer()  
9 X, y = data.data, data.target  
10  
11 # Split stratifié 70/15/15  
12 X_train, X_tmp, y_train, y_tmp = train_test_split(  
13     X, y, test_size=0.30, random_state=42, stratify=y)  
14 X_val, X_test, y_val, y_test = train_test_split(  
15     X_tmp, y_tmp, test_size=0.50, random_state=42,  
16     stratify=y_tmp)
```

```

17 # Normalisation (fit sur train UNIQUEMENT)
18 scaler = StandardScaler()
19 X_train = scaler.fit_transform(X_train)
20 X_val    = scaler.transform(X_val)
21 X_test   = scaler.transform(X_test)
22
23 # Conversion en tenseurs
24 def to_loader(X, y, batch_size=32, shuffle=True):
25     ds = TensorDataset(torch.FloatTensor(X),
26                        torch.LongTensor(y))
27     return DataLoader(ds, batch_size=batch_size,
28                       shuffle=shuffle)
29
30 train_loader = to_loader(X_train, y_train, shuffle=True)
31 val_loader   = to_loader(X_val,   y_val,   shuffle=False)
32 test_loader  = to_loader(X_test,  y_test,  shuffle=False)

```

Listing 2.4 – Préparation complète des données

Attention : data leakage

Le `StandardScaler` est **uniquement** fitté sur le **train set**. Appliquer `fit_transform` sur l'ensemble complet constitue une fuite d'information (*data leakage*) qui conduit à des métriques artificiellement optimistes.

2.3 Implémentation des modèles

2.3.1 Version `nn.Sequential`

```

1 model_seq = nn.Sequential(
2     nn.Linear(30, 128),
3     nn.BatchNorm1d(128),
4     nn.ReLU(),
5     nn.Dropout(0.3),
6     nn.Linear(128, 64),
7     nn.BatchNorm1d(64),
8     nn.ReLU(),
9     nn.Dropout(0.3),
10    nn.Linear(64, 32),
11    nn.ReLU(),
12    nn.Linear(32, 2)
13 )

```

Listing 2.5 – MLP avec nn.Sequential

2.3.2 Version classe personnalisée

La version classe personnalisée (présentée en section 2.1.2) offre plus de flexibilité : connexions résiduelles, sorties intermédiaires, etc.

2.3.3 Boucle d'entraînement

```
1 optimizer = torch.optim.Adam(model.parameters(), lr=1e-3,
    weight_decay=1e-4)
2 criterion = nn.CrossEntropyLoss()
3 scheduler = torch.optim.lr_scheduler.ReduceLROnPlateau(
4     optimizer, patience=5, factor=0.5)
5
6 best_val_loss = float("inf")
7 patience_counter = 0
8 PATIENCE = 10
9
10 for epoch in range(1, 101):
11     # --- Entraînement ---
12     model.train()
13     for X_b, y_b in train_loader:
14         X_b, y_b = X_b.to(device), y_b.to(device)
15         optimizer.zero_grad()
16         logits = model(X_b)
17         loss = criterion(logits, y_b)
18         loss.backward()
19         optimizer.step()
20
21     # --- Validation ---
22     model.eval()
23     val_loss = 0
24     with torch.no_grad():
25         for X_b, y_b in val_loader:
26             logits = model(X_b.to(device))
27             val_loss += criterion(logits,
28                                 y_b.to(device)).item()
29     val_loss /= len(val_loader)
30     scheduler.step(val_loss)
```

```

31     # Early stopping
32     if val_loss < best_val_loss:
33         best_val_loss = val_loss
34         torch.save(model.state_dict(), "best_model.pth")
35         patience_counter = 0
36     else:
37         patience_counter += 1
38         if patience_counter >= PATIENCE:
39             print(f"Early stopping at epoch {epoch}")
40             break

```

Listing 2.6 – Boucle d’entraînement avec early stopping

2.4 Résultats expérimentaux

2.4.1 Comparaison des initialisations

TABLE 2.1 – Impact de l’initialisation sur les performances (validation set)

Initialisation	Accuracy	F1-score	Époques conv.	Val. Loss finale
Constante ($c = 0.01$)	94.1 %	0.932	87	0.218
Gaussienne ($\sigma = 0.01$)	95.3 %	0.948	62	0.187
Xavier	97.6 %	0.973	41	0.142

2.4.2 Métriques finales sur le test set

TABLE 2.2 – Performances du meilleur MLP (Xavier, test set)

Classe	Précision	Rappel	F1-score	Support
Malin (0)	0.971	0.962	0.966	32
Bénin (1)	0.979	0.985	0.982	54
Macro avg	0.975	0.974	0.974	86

2.4.3 Visualisation de la convergence




FIGURE 2.1 – Courbes d'apprentissage du MLP (Xavier, 41 époques)

2.5 Question de synthèse — Partie I

Dans quelle mesure un MLP bien paramétré constitue-t-il une solution pertinente pour la classification tabulaire, et quelles sont ses principales limites ?

Le dataset *Breast Cancer Wisconsin* illustre parfaitement le cas d'usage optimal du MLP : des features numériques indépendantes, sans structure spatiale ni temporelle. Un MLP avec architecture en entonnoir (128→64→32), initialisation Xavier, Batch Normalization et Dropout atteint **97.6 % d'accuracy** en test, avec un F1-score macro de 0.974. Ces résultats confirment que le MLP est une solution pertinente lorsque la structure statistique des données est *non géométrique*.

Cependant, plusieurs limites doivent être soulignées :

1. **Absence de biais inductif** : le MLP ne fait aucune hypothèse sur la structure des données. Pour des images ou des séquences, cet avantage devient un inconvénient car il augmente drastiquement le nombre de paramètres nécessaires.
2. **Sensibilité à la normalisation** : contrairement aux arbres de décision, le MLP est fortement affecté par les échelles des features. Le `StandardScaler` est indispensable.
3. **Interprétabilité limitée** : bien que SHAP permette d'estimer la contribution de chaque feature, le MLP reste une boîte noire comparée aux modèles linéaires.
4. **Données tabulaires hétérogènes** : en présence de nombreuses variables catégorielles ou de relations non-monotones complexes, des modèles à base de gradient

boosting (XGBoost, LightGBM) surpassent fréquemment le MLP.

En conclusion, le MLP constitue une **baseline solide et rapide** pour les données tabulaires numériques, mais son utilisation doit être motivée par la nature des données.

Chapitre 3

Partie II — CNN et Vision par Ordinateur

3.1 Cadre théorique

3.1.1 Limites du MLP pour les images

Un MLP appliqué à une image $224 \times 224 \times 3$ nécessiterait une couche d'entrée de 150 528 neurones, menant à des centaines de millions de paramètres pour la première couche cachée. De plus, le MLP ne respecte pas la *localité spatiale* : deux pixels adjacents ont le même poids qu'un pixel distant.

Les CNN résolvent ces problèmes grâce à trois idées fondatrices [2] :

Idées fondatrices des CNN

1. **Localité** : chaque neurone ne perçoit qu'un champ récepteur local.
2. **Partage des poids** : le même filtre est appliqué en tous les points de l'image (invariance par translation).
3. **Hiérarchie des représentations** : les couches successives apprennent des features de complexité croissante (bords $\rightarrow$ textures $\rightarrow$ objets).

3.1.2 Corrélacion croisée 2D

Définition 3.1 (Corrélacion croisée 2D). *Pour une entrée $\mathbf{X} \in \mathbb{R}^{H \times W}$ et un noyau $\mathbf{K} \in \mathbb{R}^{k_h \times k_w}$, la sortie est :*

$$(\mathbf{X} \star \mathbf{K})[i, j] = \sum_{m=0}^{k_h-1} \sum_{n=0}^{k_w-1} \mathbf{X}[i+m, j+n] \cdot \mathbf{K}[m, n] \quad (3.1)$$

Calcul manuel (exemple) : entrée 4×4 , noyau 3×3 , stride 1, padding 0.

$$H_{\text{out}} = \left\lfloor \frac{H - k_h + 2p}{s} \right\rfloor + 1 = \left\lfloor \frac{4 - 3 + 0}{1} \right\rfloor + 1 = 2 \quad (3.2)$$

La sortie est donc de taille 2×2 .

3.1.3 Pooling

$$\text{Max-pooling : } (\mathbf{X} \downarrow)[i, j] = \max_{m, n \in \mathcal{R}_{ij}} \mathbf{X}[m, n] \quad (3.3)$$

$$\text{Average-pooling : } (\mathbf{X} \downarrow)[i, j] = \frac{1}{k_h k_w} \sum_{m, n \in \mathcal{R}_{ij}} \mathbf{X}[m, n] \quad (3.4)$$

3.1.4 Implémentations manuelles

```

1 import torch
2 import torch.nn.functional as F
3
4 def cross_corr2d_manual(X, K):
5     """Correlation croisee 2D sans PyTorch."""
6     kh, kw = K.shape
7     Y = torch.zeros(X.shape[0]-kh+1, X.shape[1]-kw+1)
8     for i in range(Y.shape[0]):
9         for j in range(Y.shape[1]):
10             Y[i,j] = (X[i:i+kh, j:j+kw] * K).sum()
11     return Y
12
13 def maxpool2d_manual(X, pool_size=2):
14     ph, pw = pool_size, pool_size
15     Y = torch.zeros(X.shape[0]//ph, X.shape[1]//pw)
16     for i in range(Y.shape[0]):
17         for j in range(Y.shape[1]):
18             Y[i,j] = X[i*ph:(i+1)*ph, j*pw:(j+1)*pw].max()
19     return Y
20
21 # Verification avec PyTorch
22 X = torch.randn(5, 5)
23 K = torch.randn(3, 3)
24 out_manual = cross_corr2d_manual(X, K)
25 out_torch = F.conv2d(X.unsqueeze(0).unsqueeze(0),

```

```

26         K.unsqueeze(0).unsqueeze(0)).squeeze()
27 print(f"Difference max : {(out_manual -
    out_torch).abs().max():.2e}")
28 # => Difference max : ~1e-6 (erreur numerique flottante)

```

Listing 3.1 – Corrélation croisée 2D manuelle

3.2 Dataset et préparation

3.2.1 Choix : CIFAR-10

CIFAR-10 contient **60 000 images** 32×32 en couleur (RGB), réparties en 10 classes équilibrées (6 000 par classe). Le split officiel est 50 000/10 000 (train/test).

```

1 import torchvision
2 import torchvision.transforms as T
3
4 transform_train = T.Compose([
5     T.RandomCrop(32, padding=4),
6     T.RandomHorizontalFlip(p=0.5),
7     T.ColorJitter(brightness=0.2, contrast=0.2),
8     T.ToTensor(),
9     T.Normalize(mean=[0.4914, 0.4822, 0.4465],
10                 std=[0.2470, 0.2435, 0.2616]),
11 ])
12 transform_test = T.Compose([
13     T.ToTensor(),
14     T.Normalize(mean=[0.4914, 0.4822, 0.4465],
15                 std=[0.2470, 0.2435, 0.2616]),
16 ])
17
18 trainset = torchvision.datasets.CIFAR10(
19     root="./data", train=True, download=True,
20     transform=transform_train)
21 testset = torchvision.datasets.CIFAR10(
22     root="./data", train=False, download=True,
23     transform=transform_test)

```

Listing 3.2 – Chargement CIFAR-10 avec augmentation

3.3 Architecture CNN (inspirée de LeNet)

```

1 class LeNetCIFAR(nn.Module):
2     def __init__(self, num_classes=10):
3         super().__init__()
4         self.features = nn.Sequential(
5             # Bloc 1
6             nn.Conv2d(3, 32, kernel_size=3, padding=1),
7             nn.BatchNorm2d(32), nn.ReLU(),
8             nn.Conv2d(32, 32, kernel_size=3, padding=1),
9             nn.BatchNorm2d(32), nn.ReLU(),
10            nn.MaxPool2d(2, 2),                % 32 -> 16
11            nn.Dropout2d(0.25),
12            # Bloc 2
13            nn.Conv2d(32, 64, kernel_size=3, padding=1),
14            nn.BatchNorm2d(64), nn.ReLU(),
15            nn.Conv2d(64, 64, kernel_size=1), % Conv 1x1
16            nn.BatchNorm2d(64), nn.ReLU(),
17            nn.MaxPool2d(2, 2),                % 16 -> 8
18            nn.Dropout2d(0.25),
19            # Bloc 3
20            nn.Conv2d(64, 128, kernel_size=3, padding=1),
21            nn.BatchNorm2d(128), nn.ReLU(),
22            nn.AdaptiveAvgPool2d((4, 4)),      % -> 4x4
23        )
24        self.classifier = nn.Sequential(
25            nn.Flatten(),
26            nn.Linear(128*4*4, 256),
27            nn.ReLU(), nn.Dropout(0.5),
28            nn.Linear(256, num_classes),
29        )
30
31    def forward(self, x):
32        return self.classifier(self.features(x))

```

Listing 3.3 – CNN personnalisé inspiré de LeNet

3.4 Étude expérimentale

3.4.1 Influence des hyperparamètres architecturaux

TABLE 3.1 – Impact des choix architecturaux sur CIFAR-10 (accuracy test)

Configuration	Accuracy test	Paramètres (M)
MLP baseline (784→512→256→10)	52.1 %	0.84
CNN sans padding	74.3 %	0.23
CNN + padding=1	78.8 %	0.24
CNN + padding + Max-pool	81.2 %	0.24
CNN + padding + Avg-pool	79.6 %	0.24
CNN + Conv 1×1	82.4 %	0.27
LeNetCIFAR (complet)	84.7 %	0.52

3.4.2 Courbes d'apprentissage




FIGURE 3.1 – Comparaison MLP vs CNN sur CIFAR-10

3.5 Question de synthèse — Partie II

Pourquoi un CNN est-il plus pertinent qu'un MLP pour la classification d'images, et comment les choix architecturaux influencent-ils les performances ?

Les résultats montrent sans ambiguïté la supériorité du CNN (+32.6 points d'accuracy par rapport au MLP sur CIFAR-10). Cette différence s'explique par les biais inductifs fondamentaux :

1. Localité et partage des poids. Un filtre 3×3 avec 32 canaux ne représente que $3 \times 3 \times 3 \times 32 = 864$ paramètres, contre des millions pour une couche *fully connected*

équivalente. Le partage des poids impose une invariance par translation qui correspond exactement à la nature des images naturelles.

2. Impact du padding. Le padding préserve les dimensions spatiales et permet au réseau de traiter les bords de l'image, améliorant l'accuracy de +4.5 points (tableau 3.1).

3. Type de pooling. Le max-pooling (+1.6 vs avg-pooling) sélectionne les activations les plus saillantes, agissant comme un détecteur de présence de feature.

4. Approximation 1×1 . La Conv 1×1 agit comme une projection linéaire inter-canaux, augmentant la capacité sans coût spatial (+2.3 points).

Limites observées. Le CNN LeNetCIFAR plafonne à $\sim 84.7\%$ sur CIFAR-10. Des architectures plus profondes (ResNet, VGG) avec des connexions résiduelles atteignent 93–95 %. La profondeur devient un goulot d'étranglement car le gradient s'atténue lors de la rétropropagation à travers de nombreuses couches.

Chapitre 4

Partie III — RNN, LSTM, GRU et Seq2Seq

4.1 Cadre théorique

4.1.1 Modèles de langage

Définition 4.1 (Modèle de langage). *Un modèle de langage estime la probabilité d’une séquence de tokens $\mathbf{x} = (x_1, x_2, \dots, x_T)$ en appliquant la règle de la chaîne :*

$$P(\mathbf{x}) = \prod_{t=1}^T P(x_t \mid x_1, \dots, x_{t-1}) \quad (4.1)$$

Définition 4.2 (Perplexité). *La perplexité est la mesure standard d’évaluation d’un modèle de langage :*

$$\text{PPL}(\mathbf{x}) = \exp\left(-\frac{1}{T} \sum_{t=1}^T \log P(x_t \mid x_1, \dots, x_{t-1})\right) \quad (4.2)$$

Une perplexité de k signifie que le modèle est aussi incertain que face à k choix équiprobables à chaque étape.

4.1.2 RNN simple et ses limites

L’équation d’état du RNN simple est :

$$\mathbf{h}_t = \tanh(\mathbf{W}_h \mathbf{h}_{t-1} - 1 + \mathbf{W}_x \mathbf{h}_{t-1} \mathbf{x}_t + \mathbf{b}_h) \quad (4.3)$$

Le gradient du RNN à travers le temps (BPTT) est :

$$\frac{\partial \mathcal{L}}{\partial \mathbf{h}_1} = \frac{\partial \mathcal{L}}{\partial \mathbf{h}_T} \prod_{t=2}^T \frac{\partial \mathbf{h}_t}{\partial \mathbf{h}_{t-1}} = \frac{\partial \mathcal{L}}{\partial \mathbf{h}_T} \prod_{t=2}^T \mathbf{W}_{hh}^\top \cdot \text{diag}(\tanh')$$
 (4.4)

Si $\|\mathbf{W}_{hh}\| < 1$, le gradient *disparaît* exponentiellement. Si $\|\mathbf{W}_{hh}\| > 1$, il *explose*. Le gradient clipping résout l'explosion :

$$\hat{\mathbf{g}} = \min\left(1, \frac{c}{\|\mathbf{g}\|}\right) \mathbf{g}, \quad c = 1.0$$
 (4.5)

4.1.3 LSTM

Équations du LSTM [4]

$$\mathbf{f}_t = \sigma(\mathbf{W}_f[\mathbf{h}_{t-1}; \mathbf{x}_t] + \mathbf{b}_f) \quad (\text{porte d'oubli}) \quad (4.6)$$

$$\mathbf{i}_t = \sigma(\mathbf{W}_i[\mathbf{h}_{t-1}; \mathbf{x}_t] + \mathbf{b}_i) \quad (\text{porte d'entrée}) \quad (4.7)$$

$$\tilde{\mathbf{c}}_t = \tanh(\mathbf{W}_c[\mathbf{h}_{t-1}; \mathbf{x}_t] + \mathbf{b}_c) \quad (\text{candidat}) \quad (4.8)$$

$$\mathbf{c}_t = \mathbf{f}_t \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{c}}_t \quad (\text{état de cellule}) \quad (4.9)$$

$$\mathbf{o}_t = \sigma(\mathbf{W}_o[\mathbf{h}_{t-1}; \mathbf{x}_t] + \mathbf{b}_o) \quad (\text{porte de sortie}) \quad (4.10)$$

$$\mathbf{h}_t = \mathbf{o}_t \odot \tanh(\mathbf{c}_t) \quad (\text{état caché}) \quad (4.11)$$

4.1.4 GRU

Le GRU [4] simplifie le LSTM en fusionnant les portes d'oubli et d'entrée :

$$\mathbf{z}_t = \sigma(\mathbf{W}_z[\mathbf{h}_{t-1}; \mathbf{x}_t]) \quad (\text{porte de mise à jour}) \quad (4.12)$$

$$\mathbf{r}_t = \sigma(\mathbf{W}_r[\mathbf{h}_{t-1}; \mathbf{x}_t]) \quad (\text{porte de réinitialisation}) \quad (4.13)$$

$$\tilde{\mathbf{h}}_t = \tanh(\mathbf{W}[\mathbf{r}_t \odot \mathbf{h}_{t-1}; \mathbf{x}_t]) \quad (4.14)$$

$$\mathbf{h}_t = (1 - \mathbf{z}_t) \odot \mathbf{h}_{t-1} + \mathbf{z}_t \odot \tilde{\mathbf{h}}_t \quad (4.15)$$

4.2 Dataset et préparation

4.2.1 Choix : corpus fra-eng (Tatoeba)

Le corpus *fra-eng* de Tatoeba contient environ 135 000 paires de phrases anglais-français. Nous en utilisons un sous-ensemble de **50 000 paires** pour une traduction automatique

neuronale simplifiée (Seq2Seq).

```

1 import re
2 from collections import Counter
3
4 class Vocab:
5     PAD, BOS, EOS, UNK = 0, 1, 2, 3
6
7     def __init__(self, tokens, min_freq=2, max_size=10000):
8         counter = Counter(tokens)
9         self.itos = ["<pad>", "<bos>", "<eos>", "<unk>"] + \
10             [w for w, c in
11                 counter.most_common(max_size)
12                 if c >= min_freq]
13         self.stoi = {w:i for i, w in enumerate(self.itos)}
14
15     def encode(self, seq):
16         return [self.stoi.get(w, self.UNK) for w in seq]
17
18     def tokenize(text, lang="en"):
19         text = text.lower().strip()
20         text = re.sub(r"([!?\])", r" \1", text)
21         return text.split()
22
23 # Padding + batch
24 def collate_fn(batch):
25     src, tgt = zip(*batch)
26     src_pad = nn.utils.rnn.pad_sequence(
27         src, batch_first=True, padding_value=Vocab.PAD)
28     tgt_pad = nn.utils.rnn.pad_sequence(
29         tgt, batch_first=True, padding_value=Vocab.PAD)
30     return src_pad, tgt_pad

```

Listing 4.1 – Tokenisation et préparation des données séquentielles

4.3 Implémentation des modèles

4.3.1 RNN, LSTM et GRU

```

1 class SeqModel(nn.Module):
2     def __init__(self, vocab_size, embed_dim, hidden_size,
3                 num_layers, cell_type="lstm", dropout=0.3):

```

```

4     super().__init__()
5     self.embedding = nn.Embedding(vocab_size, embed_dim,
6                                   padding_idx=0)
7     rnn_cls = {"rnn": nn.RNN, "lstm": nn.LSTM,
8               "gru": nn.GRU}[cell_type]
9     self.rnn = rnn_cls(
10         embed_dim, hidden_size,
11         num_layers=num_layers,
12         batch_first=True,
13         dropout=dropout if num_layers > 1 else 0,
14         bidirectional=False,
15     )
16     self.fc = nn.Linear(hidden_size, vocab_size)
17
18     def forward(self, x):
19         emb = self.embedding(x)
20         out, _ = self.rnn(emb)
21         return self.fc(out)

```

Listing 4.2 – Classe générique RNN/LSTM/GRU

4.3.2 Architecture Seq2Seq

```

1 class Encoder(nn.Module):
2     def __init__(self, src_vocab, embed_dim, hidden_size,
3                   num_layers, dropout):
4         super().__init__()
5         self.embedding = nn.Embedding(src_vocab, embed_dim,
6                                       padding_idx=0)
7         self.lstm = nn.LSTM(embed_dim, hidden_size,
8                             num_layers=num_layers,
9                             batch_first=True,
10                            dropout=dropout)
11
12         self.dropout = nn.Dropout(dropout)
13
14     def forward(self, src):
15         emb = self.dropout(self.embedding(src))
16         outputs, (h, c) = self.lstm(emb)
17         return outputs, h, c

```

Listing 4.3 – Encodeur Seq2Seq

```

1 class Decoder(nn.Module):

```

```

2     def __init__(self, tgt_vocab, embed_dim, hidden_size,
3                   num_layers, dropout):
4         super().__init__()
5         self.embedding = nn.Embedding(tgt_vocab, embed_dim,
6                                       padding_idx=0)
7         self.lstm = nn.LSTM(embed_dim, hidden_size,
8                             num_layers=num_layers,
9                             batch_first=True,
10                            dropout=dropout)
11         self.fc = nn.Linear(hidden_size, tgt_vocab)
12         self.dropout = nn.Dropout(dropout)
13
14     def forward(self, tgt_token, h, c):
15         tgt = tgt_token.unsqueeze(1)           # (B, 1)
16         emb = self.dropout(self.embedding(tgt))
17         out, (h, c) = self.lstm(emb, (h, c))   # out: (B,1,H)
18         logits = self.fc(out.squeeze(1))      # (B,
19                                             tgt_vocab)
20         return logits, h, c
21
22 class Seq2Seq(nn.Module):
23     def __init__(self, encoder, decoder, device):
24         super().__init__()
25         self.encoder = encoder
26         self.decoder = decoder
27         self.device = device
28
29     def forward(self, src, tgt, teacher_forcing_ratio=0.5):
30         B, T = tgt.shape
31         vocab_size = self.decoder.fc.out_features
32         outputs = torch.zeros(B, T,
33                               vocab_size).to(self.device)
34         _, h, c = self.encoder(src)
35         token = tgt[:, 0] # <bos>
36         for t in range(1, T):
37             logit, h, c = self.decoder(token, h, c)
38             outputs[:, t] = logit
39             use_tf = torch.rand(1).item() <
40                 teacher_forcing_ratio
41             token = tgt[:, t] if use_tf else logit.argmax(1)
42         return outputs

```

Listing 4.4 – Décodeur Seq2Seq avec Teacher Forcing

4.3.3 Décodage : glouton et beam search

```

1 def beam_search(model, src, vocab, beam_width=5, max_len=50):
2     model.eval()
3     with torch.no_grad():
4         _, h, c = model.encoder(src)
5         beams = [(0.0, [vocab.BOS], h, c)]
6
7         for _ in range(max_len):
8             candidates = []
9             for score, seq, h, c in beams:
10                 if seq[-1] == vocab.EOS:
11                     candidates.append((score, seq, h, c))
12                     continue
13                 token =
14                     torch.tensor([seq[-1]]).to(src.device)
15                 logit, h_new, c_new = model.decoder(token,
16                     h, c)
17                 log_probs = torch.log_softmax(logit, dim=-1)
18                 top_probs, top_ids =
19                     log_probs.topk(beam_width)
20                 for p, idx in zip(top_probs[0], top_ids[0]):
21                     candidates.append((
22                         score + p.item(),
23                         seq + [idx.item()],
24                         h_new, c_new
25                     ))
26                 beams = sorted(candidates, key=lambda
27                     x: -x[0])[:beam_width]
28
29     best = max(beams, key=lambda x: x[0])
30     return best[1]

```

Listing 4.5 – Beam Search (beam_width=5)

4.4 Résultats expérimentaux

4.4.1 Comparaison RNN / LSTM / GRU

TABLE 4.1 – Comparaison des architectures récurrentes sur le corpus fra-eng

Modèle	PPL ↓	BLEU ↑	Params	Temps/époque	Stabilité
RNN simple	48.3	12.1	2.1M	45s	Faible
GRU	31.7	19.4	3.8M	62s	Bonne
LSTM	27.2	22.8	4.9M	74s	Excellente
LSTM Seq2Seq	22.1	28.6	7.2M	98s	Très bonne
Seq2Seq + Beam	22.1	31.4	7.2M	—	Très bonne

4.4.2 Effet du gradient clipping




FIGURE 4.1 – Explosion du gradient sans clipping vs comportement stable avec $c = 1.0$

4.5 Question de synthèse — Partie III

Dans quelle mesure les architectures récurrentes permettent-elles de modéliser efficacement une séquence réelle, et comment justifier la progression RNN → LSTM/GRU → Seq2Seq ?

Du RNN au LSTM/GRU. Le RNN simple échoue à modéliser des dépendances longues à cause de la disparition du gradient (PPL = 48.3). Le LSTM, grâce à sa cellule de mémoire et ses trois portes, maintient un gradient stable sur des centaines de pas de temps (PPL = 27.2, +44 %). Le GRU offre un compromis intéressant avec 23 % moins de paramètres pour un BLEU proche du LSTM (-3.4 points).

Du LSTM au Seq2Seq. La traduction requiert de comprendre une phrase complète avant de générer la traduction. L'architecture encodeur-décodeur permet exactement cela : l'encodeur compresse la phrase source en un vecteur de contexte, le décodeur génère la traduction de manière auto-régressive. Le gain est significatif (+5.8 points BLEU). Le Teacher Forcing accélère la convergence en fournissant le token correct à chaque étape de décodage, mais crée un écart train/test (*exposure bias*).

Beam search vs décodage glouton. Le beam search explore $k = 5$ hypothèses en parallèle, choisissant la séquence de score log-probabilité maximal. Le gain de +2.8 BLEU ($28.6 \rightarrow 31.4$) confirme que le décodage glouton peut rater des traductions globalement meilleures.

Limites observées. Les RNN souffrent d'une complexité temporelle en $O(T)$ non parallélisable. Les Transformers [5] surpassent systématiquement les RNN sur les corpus larges grâce au mécanisme d'attention, mais requièrent davantage de données et de ressources.

Chapitre 5

Discussion Transversale Finale

Comment le deep learning adapte-t-il ses architectures à la structure des données — tabulaire, image et séquentielle — et pourquoi le même paradigme d'apprentissage supervisé doit-il être décliné différemment selon la géométrie, la dépendance locale, la temporalité et la représentation des données ?

5.1 Unité du paradigme : gradient et rétropropagation

Les trois architectures étudiées partagent le même cadre théorique : minimiser une perte $\mathcal{L}$ par descente de gradient stochastique, calculée par rétropropagation. La règle de mise à jour est identique :

$$\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} - \eta \nabla_{\boldsymbol{\theta}} \mathcal{L}(\boldsymbol{\theta}) \quad (5.1)$$

C'est le **biais inductif** qui diffère, c'est-à-dire l'ensemble des hypothèses que l'architecture intègre sur la structure des données.

5.2 Tableau comparatif des architectures

TABLE 5.1 – Comparaison des biais inductifs des trois architectures

Critère	MLP	CNN	RNN/LSTM	Seq2Seq
Biais inductif	Aucun	Localité spa- tiale	Temporalité	Séquence glo- bale
Structure cible	Tabulaire	Grille 2D	Séquence	Séquence→Séquence
Paramètres	Modéré	Faible (par- tage)	Modéré	Élevé
Parallélisme	Total	Total	Séquentiel	Séquentiel
Mémoire contextuelle	Nulle	Locale	Courte/Longue	Globale
Résultats ob- tenus	97.6 % acc.	84.7 % acc.	PPL 27.2	BLEU 31.4

5.3 Adéquation données–modèle : la clé du succès

La leçon principale de ce projet est que **l'adéquation entre la structure des données et le biais inductif de l'architecture est le déterminant principal des performances**. Appliquer un MLP à des images, ou un CNN à des données tabulaires, conduit systématiquement à des résultats inférieurs au modèle adapté.

Cette adéquation se décline selon quatre dimensions :

1. **Géométrie** : les images ont une structure de grille régulière ; les CNN exploitent cette régularité via la convolution.
2. **Dépendance locale** : les pixels voisins sont corrélés ; le champ récepteur limité du CNN capture cette dépendance à coût constant.
3. **Temporalité** : les tokens d'une phrase ont un ordre crucial ; les RNN/LSTM maintiennent un état caché qui encode le contexte passé.
4. **Représentation** : les données tabulaires n'ont aucune structure géométrique implicite ; le MLP, sans biais inductif, est approprié.

5.4 Perspectives : au-delà des architectures classiques

Les Transformers [5] généralisent l'attention à toutes les architectures (Vision Transformers pour les images, BERT/GPT pour le texte), brouillant les frontières entre CNN et RNN. Ils représentent l'état de l'art actuel mais requièrent des quantités massives de données et de calcul, ce qui limite leur accessibilité dans des contextes pédagogiques comme celui de ce projet.

Chapitre 6

Conclusion

Ce projet a permis d’explorer de façon rigoureuse les trois grandes familles d’architectures de deep learning, en reliant systématiquement théorie, implémentation et expérimentation.

Résultats clés :

- Le MLP atteint **97.6 %** d’accuracy sur Breast Cancer Wisconsin, confirmant son efficacité pour les données tabulaires numériques.
- Le CNN LeNetCIFAR atteint **84.7 %** sur CIFAR-10, surpassant le MLP de +32.6 points grâce au biais inductif spatial.
- Le LSTM Seq2Seq avec beam search atteint **BLEU = 31.4** sur fra-eng, démontrant la pertinence de l’encodeur-décodeur pour la traduction.

Leçons méthodologiques :

- L’initialisation Xavier et le Batch Normalization sont essentiels à la convergence rapide.
- Le gradient clipping est indispensable pour les RNN afin d’éviter l’explosion du gradient.
- Le beam search améliore systématiquement la qualité de décodage par rapport à l’approche gloutonne.
- La rigueur expérimentale (seeds fixes, early stopping, data leakage évité) garantit la reproductibilité et la fiabilité des conclusions.

Perspectives. L’intégration de mécanismes d’attention dans les architectures récurrentes, puis le passage aux Transformers, constitue la prochaine étape naturelle pour améliorer les performances sur les tâches séquentielles, au prix d’une complexité architecturale et computationnelle accrue.

Bibliographie

- [1] X. GLOROT et Y. BENGIO, “Understanding the difficulty of training deep feedforward neural networks,” t. 9, p. 249-256, 2010.
- [2] Y. LECUN, L. BOTTOU, Y. BENGIO et P. HAFFNER, “Gradient-based learning applied to document recognition,” *Proceedings of the IEEE*, t. 86, n° 11, p. 2278-2324, 1998. DOI : [10.1109/5.726791](https://doi.org/10.1109/5.726791)
- [3] S. HOCHREITER et J. SCHMIDHUBER, “Long Short-Term Memory,” *Neural Computation*, t. 9, n° 8, p. 1735-1780, 1997. DOI : [10.1162/neco.1997.9.8.1735](https://doi.org/10.1162/neco.1997.9.8.1735)
- [4] K. CHO et al., “Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation,” *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, p. 1724-1734, 2014.
- [5] A. VASWANI et al., “Attention Is All You Need,” *Advances in Neural Information Processing Systems (NeurIPS)*, t. 30, p. 5998-6008, 2017.

Annexe A

Hyperparamètres complets

TABLE A.1 – Hyperparamètres finaux des trois modèles

Hyperparamètre	MLP	CNN	LSTM Seq2Seq
Optimiseur	Adam	Adam	Adam
Learning rate	1e-3	1e-3	5e-4
Weight decay	1e-4	1e-4	1e-5
Batch size	32	64	128
Époques	41 (ES)	50 (ES)	30 (ES)
Dropout	0.3	0.25/0.5	0.3
Scheduler	ReduceLROp	StepLR	ReduceLROp
Seed	42	42	42

Annexe B

Checklist de reproductibilité

```
1 import torch, numpy as np, random
2
3 SEED = 42
4 torch.manual_seed(SEED)
5 torch.cuda.manual_seed_all(SEED)
6 np.random.seed(SEED)
7 random.seed(SEED)
8 torch.backends.cudnn.deterministic = True
9 torch.backends.cudnn.benchmark    = False
```

Listing B.1 – Configuration reproductible

B.1 Annexe C - Requirements.txt

Le fichier `requirements.txt` garantissant l'installation de l'environnement virtuel contient les directives suivantes :

```
pandas==2.2.0
numpy==1.26.4
matplotlib==3.8.2
seaborn==0.13.2
scikit-learn==1.4.0
```